

Universidade Federal de Minas Gerais

Departamento de Engenharia Eletrônica – DELT

Engenharia de Controle e Automação

Trabalho Prático 1

Teoria da Probabilidade – Revisão

Pedro Antonio de Souza Campos Rodrigues

EEE935 – Robótica Probabilística

Prof. Rogerio Rodrigues Lima

Belo Horizonte – MG

2026

Sumário

1	Exercícios Teóricos	2
1.1	Exercício 1 – Axiomas e União de Eventos	2
1.2	Exercício 2 – Função Massa de Probabilidade (PMF)	3
1.3	Exercício 3 – Função Densidade de Probabilidade (PDF)	4
1.4	Exercício 4 – Transformação Linear	5
1.5	Exercício 5 – Covariância e Geometria	6
1.6	Exercício 6 – Modelo de Ação Discreto	9
1.7	Exercício 7 – Questões Conceituais	10
2	Exercícios Computacionais	11
2.1	Exercício 8 – Teorema do Limite Central	11
2.2	Exercício 9 – Produto de Gaussianas	13
2.3	Exercício 10 – Transformação Linear Multivariada	15

1. Exercícios Teóricos

1.1. Exercício 1 – Axiomas e União de Eventos

data / /
5 7 9 9 8 8 9


① $P(A) = 0,3$ $P(B) = 0,4$ $P(A \cap B) = 0,1$

1) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
 $= 0,3 + 0,4 - 0,1 \Rightarrow P(A \cup B) = 0,6 //$

2) $P(\bar{A}) = 1 - P(A)$
 $= 1 - 0,3 \therefore P(\bar{A}) = 0,7 //$

3) Se $A \subset B$, o que muda no cálculo?
Se $A \subset B \Rightarrow A \cup B = B$ e $A \cap B = A$
 $\therefore P(A \cup B) = P(B) = 0,4$ e $P(A \cap B) = P(A) = 0,3 //$

4)



• Ao fazer $P(A) + P(B)$ a região $A \cap B$ é contada duas vezes, então subtraímos uma ocorrência.

5) Se A e B não independentes:
 $P(A \cap B) = P(A) \cdot P(B) = 0,3 \cdot 0,4 = 0,12 //$

Figura 1: Resolução manuscrita do Exercício 1.

1.2. Exercício 2 – Função Massa de Probabilidade (PMF)

2) $X \in \{1, 2, 3, 4, 5\}$ e $P = [0,1; 0,25; 0,4; 0,05; 0,3]$

1) Verificar se $\sum_i P_i = 1$ e $P_i \geq 0 \forall i$
 $0,1 + 0,25 + 0,4 + 0,05 + 0,3 = 1,1 \neq 1$ ||
 $\therefore$ A distribuição não é válida.

2) Normalização:
 $P'_i = \frac{P_i}{\sum P_i} \therefore P' = \frac{1}{1,1} P = [0,0909; 0,2272; 0,3636; 0,0454; 0,2727]$

3) Esperança:
 $E[X] = \sum_i X_i P'_i = 1 \cdot 0,0909 + 2 \cdot 0,2272 + 3 \cdot 0,3636 + 4 \cdot 0,0454 + 5 \cdot 0,2727$
 $\therefore E[X] \approx 3,18$ ||

4) Variância:
 $Var(X) = E[X^2] - (E[X])^2$
 $E[X^2] = 1^2 \cdot 0,0909 + 2^2 \cdot 0,2272 + 3^2 \cdot 0,3636 + 4^2 \cdot 0,0454 + 5^2 \cdot 0,2727$
 $= 11,816$
 $\therefore VAR(X) = 11,816 - 3,18^2 = 1,6942$ ||

Figura 2: Resolução manuscrita do Exercício 2.

1.3. Exercício 3 – Função Densidade de Probabilidade (PDF)




Figura 3: Resolução manuscrita do Exercício 3.

1.4. Exercício 4 – Transformação Linear

4) $X \sim N(3, 0,4^2)$
↳ variância $0,4^2$ $VAR(X) = 0,16$
↳ média 3 $E[X] = 3$

1) Temos $Y = 2X + 5$
• Como o operador $E(X)$ é linear:

$$E[2X+5] = 2E[X] + E[5] = 2 \cdot 3 + 5 = \underline{11}$$

2) $Var(2X+5) = 2^2 Var(X) = 2^2 \cdot 0,16$
 $\therefore Var(2X+5) = \underline{0,64}$

3) Pela definição:

$$Var(X) \triangleq E[(X - E[X])^2], \text{ de } Y = aX + b$$
$$Var(Y) = E[(Y - E[Y])^2] = E[(aX + b - E[aX + b])^2]$$
$$= E[(aX + b - aE[X] - b)^2] = E[a^2(X - E[X])^2]$$
$$= a^2 E[(X - E[X])^2] = a^2 Var(X)$$
$$\therefore \underline{Var(aX + b) = a^2 Var(X)}$$

Figura 4: Resolução manuscrita do Exercício 4.

1.5. Exercício 5 – Covariância e Geometria




Figura 5: Resolução manuscrita do Exercício 5.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from matplotlib.patches import Ellipse
4
5 Sigma = np.array([
6     [2.0, 1.2],
7     [1.2, 1.0]
8 ])
9
10 # Autovalores e autovetores
11 eigvals, eigvecs = np.linalg.eigh(Sigma)
12
13 idx = np.argsort(eigvals)[::-1]
14 eigvals = eigvals[idx]
15 eigvecs = eigvecs[:, idx]
16
17 v_max = eigvecs[:, 0]
18
19 if v_max[0] < 0:
20     v_max = -v_max
21
22 angle = np.degrees(np.arctan2(v_max[1], v_max[0]))
23
24 print("Autovalores:")
25 print(eigvals)
26
27 print("\nAutovetores:")
28 print(eigvecs)
29
30 print("\nDirecao de maior variancia:")
31 print(v_max)
32
33 print("\nAngulo:")
34 print(angle)
35
36 print("\nCovariancia xy:")
37 print(Sigma[0, 1])
38
39
40 # Elipse de covariancia
41 n_std = 2
42
43 width = 2 * n_std * np.sqrt(eigvals[0])
44 height = 2 * n_std * np.sqrt(eigvals[1])
45
46 fig, ax = plt.subplots()
```

```
47
48 ellipse = Ellipse(
49     (0, 0),
50     width,
51     height,
52     angle=angle,
53     fill=False
54 )
55
56 ax.add_patch(ellipse)
57
58 ax.set_xlim(-4, 4)
59 ax.set_ylim(-4, 4)
60 ax.set_aspect("equal")
61 ax.grid()
62
63 ax.set_xlabel("x")
64 ax.set_ylabel("y")
65 ax.set_title("Elipse de covariancia")
66
67 plt.show()
```

1.6. Exercício 6 – Modelo de Ação Discreto

6) Belief inicial: $b = [0,1; 0,3; 0,4; 0,2]$
 80% → move uma sala
 10% → permanece
 10% → move duas salas

1) Matriz: $T_{ij}(X_{t+1}=j | X_t=i)$

$$T = \begin{bmatrix} 0,1 & 0,8 & 0,1 & 0 \\ 0 & 0,1 & 0,6 & 0,1 \\ 0 & 0 & 0,1 & 0,9 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

2) Novo belief:

$$b' = bT = [0,01 \quad 0,11 \quad 0,29 \quad 0,59]$$

3)

Apesar da ação introduzir incerteza, a restrição na sala 4 provoca acúmulo de probabilidade nesse estado. Por isso, neste caso, o belief final torna-se mais concentrado na região à direita.

Figura 6: Resolução manuscrita do Exercício 6.

1.7. Exercício 7 – Questões Conceituais




Figura 7: Resolução manuscrita do Exercício 7.

2. Exercícios Computacionais


2.1. Exercício 8 – Teorema do Limite Central

Foram geradas 10 000 amostras de um ruído uniforme em $[-1, 1]$, da soma de três ruídos uniformes e da soma de dez ruídos uniformes independentes. Para cada conjunto foi também ajustada uma distribuição gaussiana utilizando a média e o desvio padrão das amostras.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 N = 10000
5
6 # Ruídos uniformes com média zero
7 x1 = np.random.uniform(-1, 1, N)
8
9 x3 = (
10     np.random.uniform(-1, 1, N)
11     + np.random.uniform(-1, 1, N)
12     + np.random.uniform(-1, 1, N)
13 )
14
15 x10 = sum(np.random.uniform(-1, 1, N) for _ in range(10))
16
17
18 def plot_hist(data, title):
19     mu = np.mean(data)
20     sigma = np.std(data)
21
22     x = np.linspace(data.min(), data.max(), 500)
23
24     gaussian = (
25         1 / (sigma * np.sqrt(2 * np.pi))
26         * np.exp(-0.5 * ((x - mu) / sigma) ** 2)
27     )
28
29     plt.figure()
30
31     plt.hist(
32         data,
33         bins=60,
34         density=True,
35         alpha=0.6,
36         label="Amostras"
37     )
```

```
38
39 plt.plot(
40     x,
41     gaussian,
42     linewidth=2,
43     label="Gaussiana ajustada"
44 )
45
46 plt.xlabel("Valor")
47 plt.ylabel("Densidade")
48 plt.title(title)
49 plt.grid()
50 plt.legend()
51
52 print(f"{title}:")
53 print(f"media = {mu:.4f}")
54 print(f"desvio padrao = {sigma:.4f}\n")
55
56
57 plot_hist(x1, "1 ruído uniforme")
58 plot_hist(x3, "Soma de 3 ruídos uniformes")
59 plot_hist(x10, "Soma de 10 ruídos uniformes")
60
61 plt.show()
```

Os histogramas obtidos são apresentados na Figura 8.



(a) Um ruído uniforme.

(b) Soma de três ruídos.

(c) Soma de dez ruídos.

Figura 8: Histogramas das amostras e respectivas distribuições gaussianas ajustadas.

Para uma única variável uniforme, o histograma apresenta a forma aproximadamente constante esperada. Com a soma de três variáveis, a distribuição já se aproxima de uma gaussiana, e essa aproximação torna-se ainda mais evidente para a soma de dez variáveis.

O resultado ilustra o Teorema do Limite Central: a soma de variáveis aleatórias indepen-

desse sistema tende a apresentar uma distribuição aproximadamente gaussiana à medida que o número de termos aumenta.

2.2. Exercício 9 – Produto de Gaussianas

Foram consideradas as distribuições

$$\mu_1 = 2, \quad \sigma_1 = 0,5,$$

e

$$\mu_2 = 2,3, \quad \sigma_2 = 0,3.$$

O produto normalizado das duas gaussianas foi calculado pelo código abaixo.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 mu1 = 2.0
5 sigma1 = 0.5
6
7 mu2 = 2.3
8 sigma2 = 0.3
9
10 var1 = sigma1**2
11 var2 = sigma2**2
12
13 # Produto de duas gaussianas
14 var = 1 / (1 / var1 + 1 / var2)
15
16 mu = var * (
17     mu1 / var1
18     + mu2 / var2
19 )
20
21 sigma = np.sqrt(var)
22
23 print("Gaussiana 1:")
24 print(f"media = {mu1}")
25 print(f"variância = {var1}")
26
27 print("\nGaussiana 2:")
28 print(f"media = {mu2}")
29 print(f"variância = {var2}")
```

```
30
31 print("\nProduto:")
32 print(f"media = {mu:.4f}")
33 print(f"variancia = {var:.4f}")
34 print(f"desvio padrao = {sigma:.4f}")
35
36
37 def gaussian(x, mu, sigma):
38     return (
39         1 / (sigma * np.sqrt(2 * np.pi))
40         * np.exp(-0.5 * ((x - mu) / sigma) ** 2)
41     )
42
43
44 x = np.linspace(0, 4, 1000)
45
46 p1 = gaussian(x, mu1, sigma1)
47 p2 = gaussian(x, mu2, sigma2)
48 p = gaussian(x, mu, sigma)
49
50 plt.plot(x, p1, label="Gaussiana 1")
51 plt.plot(x, p2, label="Gaussiana 2")
52 plt.plot(x, p, label="Produto")
53
54 plt.xlabel("x")
55 plt.ylabel("Densidade")
56 plt.title("Produto de Gaussianas")
57 plt.grid()
58 plt.legend()
59
60 plt.show()
```

Foram obtidos

$$\mu = 2,2206$$

e

$$\sigma^2 = 0,0662, \quad \sigma = 0,2572.$$




Figura 9: Gaussianas originais e distribuição resultante do produto normalizado.

A média resultante encontra-se entre μ_1 e μ_2 , porém mais próxima de $\mu_2 = 2,3$. Isso ocorre porque a segunda distribuição possui menor variância e, portanto, maior concentração em torno de sua média.

Além disso,

$$0,0662 < 0,09 < 0,25,$$

mostrando que a variância resultante é menor que as variâncias das duas distribuições originais.

2.3. Exercício 10 – Transformação Linear Multivariada

São dados

$$\mu = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 1 & 0,5 \\ 0,5 & 2 \end{bmatrix},$$

e

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 0,5 \end{bmatrix}.$$

Para a transformação

$$y = Ax,$$

a média e a matriz de covariância transformadas são

$$\mu' = A\mu$$

e

$$\Sigma' = A\Sigma A^T.$$

Os cálculos e a geração das elipses foram realizados pelo código abaixo.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from matplotlib.patches import Ellipse
4
5 mu = np.array([1.0, 2.0])
6
7 Sigma = np.array([
8     [1.0, 0.5],
9     [0.5, 2.0]
10 ])
11
12 A = np.array([
13     [2.0, 0.0],
14     [0.0, 0.5]
15 ])
16
17 mu_new = A @ mu
18 Sigma_new = A @ Sigma @ A.T
19
20 eigvals, eigvecs = np.linalg.eigh(Sigma)
21 eigvals_new, eigvecs_new = np.linalg.eigh(Sigma_new)
22
23 print("Media original:")
24 print(mu)
25
26 print("\nNova media:")
27 print(mu_new)
28
29 print("\nCovariancia original:")
30 print(Sigma)
```

```
31
32 print("\nNova covariancia:")
33 print(Sigma_new)
34
35 print("\nAutovalores originais:")
36 print(eigvals)
37
38 print("\nAutovalores transformados:")
39 print(eigvals_new)
40
41
42 def covariance_ellipse(ax, mu, Sigma, label):
43     values, vectors = np.linalg.eigh(Sigma)
44
45     idx = np.argsort(values)[::-1]
46     values = values[idx]
47     vectors = vectors[:, idx]
48
49     v = vectors[:, 0]
50
51     angle = np.degrees(
52         np.arctan2(v[1], v[0])
53     )
54
55     width = 4 * np.sqrt(values[0])
56     height = 4 * np.sqrt(values[1])
57
58     ellipse = Ellipse(
59         mu,
60         width,
61         height,
62         angle=angle,
63         fill=False,
64         linewidth=2,
65         label=label
66     )
67
68     ax.add_patch(ellipse)
69
70
71 fig, ax = plt.subplots()
72
73 covariance_ellipse(
74     ax,
75     mu,
76     Sigma,
77     "Original"
```

```
78 )
79
80 covariance_ellipse(
81     ax,
82     mu_new,
83     Sigma_new,
84     "Transformada"
85 )
86
87 ax.scatter(*mu)
88 ax.scatter(*mu_new)
89
90 ax.set_xlim(-3, 7)
91 ax.set_ylim(-2, 6)
92
93 ax.set_aspect("equal")
94 ax.set_xlabel("x")
95 ax.set_ylabel("y")
96 ax.grid()
97 ax.legend()
98
99 plt.show()
```

A nova média obtida foi

$$\mu' = \begin{bmatrix} 2 \\ 1 \end{bmatrix},$$

enquanto a nova matriz de covariância foi

$$\Sigma' = \begin{bmatrix} 4 & 0,5 \\ 0,5 & 0,5 \end{bmatrix}.$$

Os autovalores da matriz original são aproximadamente

$$\lambda(\Sigma) = \{0,7929, 2,2071\},$$

enquanto os autovalores da matriz transformada são

$$\lambda(\Sigma') = \{0,4300, 4,0700\}.$$




Figura 10: Elipses de covariância antes e após a transformação linear.

A transformação multiplica a coordenada x por 2 e a coordenada y por 0,5. Dessa forma, a distribuição é alongada predominantemente na direção horizontal e comprimida na direção vertical.

Os autovalores representam as variâncias nas direções principais das elipses. Assim, o aumento do maior autovalor e a redução do menor autovalor são consistentes com o alongamento e a compressão observados na Figura 10.